

Instituto de Matemática e Estatística
Universidade de São Paulo



Lista 8

MAE0330 - Análise Multivariada de Dados

Prof^a Lucia Pereira Barroso

Bruno Groper Morbin - n^oUSP 11809875

Luigi Pavarini de Lima - n^oUSP 11844642

São Paulo
19 de dezembro, 2022

Exercício 2

Considera-se o arquivo `vendedores.xlsx` para análise dos dados. Ajusta-se então um modelo de regressão multivariada, considerando o índice de crescimento de vendas(X_1) e índice de lucratividade(X_2) como variáveis respostas e Criatividade(X_4) e Habilidade matemática(X_7) como variáveis explicativas. Para o conjunto de dados, tem-se o seguinte dicionário:

- Análise do desempenho:
 - X_1 : índice de crescimento de vendas;
 - X_2 : índice de lucratividade e;
 - X_3 : índice de captação de novas vendas.
- Análise de habilidades:
 - X_4 : criatividade;
 - X_5 : raciocínio mecânico;
 - X_6 : raciocínio abstrato e;
 - X_7 : habilidade matemática.

Tabela 1: Conjunto de dados ‘vendedores.xlsx’

Rotulo	X1	X2	X3	X4	X5	X6	X7
1	93.0	96.0	97.8	9	12	9	20
2	88.8	91.8	96.8	7	10	10	15
3	95.0	100.3	99.0	8	12	9	26
4	101.3	103.8	106.8	13	14	12	29
5	102.0	107.8	103.0	10	15	12	32
6	95.8	97.5	99.3	10	14	11	21
7	95.5	99.5	99.0	9	12	9	25
8	110.8	122.0	115.3	18	20	15	51
9	102.8	108.3	103.8	10	17	13	31
10	106.8	120.5	102.0	14	18	11	39
11	103.3	109.8	104.0	12	17	12	32
12	99.5	111.8	100.3	10	18	8	31
13	103.5	112.5	107.0	16	17	11	34
14	99.5	105.5	102.3	8	10	11	34
15	100.0	107.0	102.8	13	10	8	34
16	81.5	93.5	95.0	7	9	5	16
17	101.3	105.3	102.8	11	12	11	32
18	103.3	110.8	103.5	11	14	11	35
19	95.3	104.3	103.0	5	14	13	30
20	99.5	105.3	106.3	17	17	11	27
21	88.5	95.3	95.8	10	12	7	15
22	99.3	115.0	104.3	5	11	11	42
23	87.5	92.5	95.8	9	9	7	16
24	105.3	114.0	105.3	12	15	12	37
25	107.0	121.0	109.0	16	19	12	39
26	93.3	102.0	97.8	10	15	7	23
27	106.8	118.0	107.3	14	16	12	39
28	106.8	120.0	104.8	10	16	11	49
29	92.3	90.8	99.8	8	10	13	17
30	106.3	121.0	104.5	9	17	11	44
31	106.0	119.5	110.5	18	15	10	43
32	88.3	92.8	96.8	13	11	8	10
33	96.0	103.3	100.5	7	15	11	27
34	94.3	94.5	99.0	10	12	11	19
35	106.5	121.5	110.5	18	17	10	42
36	106.5	115.5	107.0	8	13	14	47
37	92.0	99.5	103.5	18	16	8	18
38	102.0	99.8	103.3	13	12	14	28
39	108.3	122.3	108.5	15	19	12	41
40	106.8	119.0	106.8	14	20	12	37
41	102.5	109.3	103.8	9	17	13	32
42	92.5	102.5	99.3	13	15	6	23
43	102.8	113.8	106.8	17	20	10	32
44	83.3	87.3	96.3	1	5	9	15
45	94.8	101.8	99.8	7	16	11	24
46	103.5	112.0	110.8	18	13	12	37
47	89.5	96.0	97.3	7	15	11	14
48	84.3	89.8	94.3	8	8	8	9
49	104.3	109.5	106.5	14	12	12	36
50	106.0	118.5	105.0	12	16	11	39

Obtenção dos coeficientes estimados

Tem-se o seguinte modelo de regressão multivariada:

$$Y_{(n \times p)} = X_{(n \times q)} B_{(q \times p)} + U_{(n \times p)}$$

onde $X \equiv$ matriz das variáveis explicativas, $Y \equiv$ matriz das variáveis respostas, $B \equiv$ coeficientes da regressão, e $U \equiv$ erro aleatório do modelo.

Tem-se também as premissas de $\mathbb{E}(U) = 0$, $\text{Var}(U_k) = \Sigma$, onde $U_k \equiv$ k-ésima linha de U , correspondente a k-ésima unidade amostral.

No caso em questão, tem-se $n = 50$ e $p = q = 2$, portanto obtém-se os coeficientes estimados por Mínimos Quadrados da regressão multivariada através do cálculo:

$$\hat{B} = (X^T X)^{-1} X^T Y$$

```
> # Obtenção através do método multivariado
> Y = as.matrix(vendedores[c("X1", "X2")])
> X = as.matrix(vendedores[c("X4", "X7")])
>
> B_hat = solve(t(X)%*%X)%*%t(X)%*%Y
> colnames(B_hat) <- NULL; rownames(B_hat) <- NULL
>
> print(B_hat)
```

```
      [,1]      [,2]
[1,] 3.605998 3.638801
[2,] 1.756552 2.006603
```

```
> # Obtenção através do método univariado
> y = c(Y)
> x = kronecker(diag(1, nrow=2), X)
>
> b_hat = solve(t(x)%*%x)%*%t(x)%*%y
> print(b_hat)
```

```
      [,1]
[1,] 3.605998
[2,] 1.756552
[3,] 3.638801
[4,] 2.006603
```

Nota-se que `b_hat` (obtido pelo método univariado) é equivalente a `vec(B_hat)` obtido pelo método multivariado.

Verificação de normalidade multivariada

Para verificar uma das premissas do modelo que trata da normalidade multivariada do erro aleatório, calcula-se a distância de Mahalanobis obtida por:

$$(D_M)_i = \sqrt{(\epsilon_i - \mu_\epsilon)^T S^{-1} (\epsilon_i - \mu_\epsilon)}$$

sendo $\epsilon_i \equiv$ resíduos do ajuste da i-ésima unidade amostral, $\mu_\epsilon \equiv$ média amostral dos resíduos ajustados sendo representada por um vetor coluna, e $S \equiv$ matriz de covariância dos resíduos amostral, ou seja $S = \frac{1}{n-1} \sum_{j=1}^n (\epsilon_j - \mu_\epsilon)(\epsilon_j - \mu_\epsilon)^T$.

Portanto, visto que $\epsilon = Y - X\hat{B}$, obtém-se as seguintes distâncias de Mahalanobis por unidade amostral:

```
> e <- Y - X%*%B_hat
> mu_e <- t(c(mean(e[1]), mean(e[2]))); mu_e
```

```
      [,1]      [,2]
[1,] 25.41497 37.20973
```

```
> S <- cov(e); S
```

```
      X1      X2
X1 445.4927 439.7480
X2 439.7480 445.1363
```

```
> D_M <- apply(e, FUN=function(x) sqrt((x-mu_e)%*%solve(S)%*%t(x-mu_e)), MARGIN=1)
> # ou equivalentemente: > sqrt(mahalanobis(e,center = mu_e, cov = S))
>
> D_M
```

```
[1] 4.237262 3.836750 4.012866 5.291878 4.431027 4.724733 4.347081 5.532128 4.417386 3.187828
[11] 4.323259 2.467348 4.149314 4.486935 4.513259 1.206779 5.026148 4.266663 3.149000 4.448741
[21] 2.726044 2.267494 3.329947 4.164182 3.351026 2.821335 3.834315 4.013288 5.337374 2.969026
[31] 4.223690 3.080665 3.460328 5.016111 3.765846 4.791342 3.263050 6.582452 3.416966 3.346177
[41] 4.078836 2.654091 3.525029 3.623647 3.309112 4.822890 2.743045 2.679526 5.230392 3.308187
```

Realiza-se o teste de Henze-Sirklers para verificar hipótese nula de normalidade multivariada.

```
> # Teste de Henze-Zirklers para normalidade multivariada
> par(cex=0.95)
> test_MN <- MVN::mvn(e,mvnTest = "hz",desc = F, multivariatePlot = "qq")
```




Figura 1: QQ-Plot para verificação da hipótese de normalidade multivariada

```
> # p-valor do teste
> library(ascii)
> print(ascii(test_MN$multivariateNormality), type = 'pandoc')
```

	Test	HZ	p value	MVN
1	Henze-Zirkler	0.53	0.38	YES

Com p-valor $> 0,05$ não rejeita-se hipótese nula e infere-se, juntamente com o gráfico QQ-Plot, que ϵ segue Normalidade Multivariada.

Teste de contrastes

Objetiva-se testar simultaneamente se os coeficientes associados a **Criatividade** nas duas funções de regressão são iguais a zero, ou seja:

$$\text{Tem-se que } B = \begin{matrix} & \begin{matrix} X1 & X2 \end{matrix} \\ \begin{matrix} X4 \\ X7 \end{matrix} & \begin{pmatrix} \beta_{11} & \beta_{12} \\ \beta_{21} & \beta_{22} \end{pmatrix} \end{matrix}$$

Logo, os coeficientes associados a **Criatividade**(X4) são β_{11} e β_{12} referentes às equações da variável resposta X1 e X2, respectivamente. Portanto, o objetivo do teste é analisar a hipótese $\{H_0 : \beta_{11} = \beta_{12} = 0\}$.

Para tal, considera-se $C_1 B M_1 = D$ para o modelo $Y = X B + U$, sob a hipótese de normalidade multivariada.

Tem-se que $\text{dimensão}(C_1) = (g \times q)$, $\text{dimensão}(M_1) = (p \times r)$, $\text{dimensão}(D) = (g \times r)$, portanto, com $\{H_0 : \beta_{11} = \beta_{12} = 0\} \Rightarrow r = 2$ restrições, $g = 1 \Rightarrow D = [0 \ 0]_{(1 \times 2)} \Rightarrow (C_1)_{(1 \times 2)}$ e $(M_1)_{(2 \times 2)}$, resultando em:

$$C_1 B M_1 = (1 \ 0) \begin{pmatrix} \beta_{11} & \beta_{12} \\ \beta_{21} & \beta_{22} \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = (0 \ 0)$$

Ou seja, $M_1 = I$ e usando o material de apoio, tem-se que a estatística do TRV é dada por:

$$\lambda^{2/n} = \frac{|Y^T P Y|}{|Y^T P Y + Y_+^T P_2 Y_+|}$$

que sob a hipótese nula, tem distribuição de Wilks $\Lambda(p, n-1, g)$. Além disso, $Y_+ = Y - X B_0$, onde B_0 tal que $C_1 B_0 = D$ e $P = I - X(X^T X)^{-1} X^T$, com $P_2 = X(X^T X)^{-1} C_1^T [C_1 (X^T X)^{-1} C_1^T]^{-1} C_1 (X^T X)^{-1} X^T$. Portanto, toma-se então:

$$C_1 B_0 = (1 \ 0) \begin{pmatrix} 0 & 0 \\ 4 & 3 \end{pmatrix} = (0 \ 0) \Rightarrow B_0 = \begin{pmatrix} 0 & 0 \\ 4 & 3 \end{pmatrix}$$

Calcula-se então a estatística do teste:

```
> n <- nrow(Y) # n = número de unidades amostrais
> Yt <- t(Y) # Y transposto
> Xt <- t(X) # X transposto
> C1 <- matrix(c(1,0),ncol=2, nrow=1) # C_1
> C1t <- t(C1)
> B0 <- matrix(c(0,0,4,3), byrow = T, ncol=2, nrow=2)
>
> P <- diag(1,nrow = n) - X%*%solve(Xt%*%X)%*%Xt # I - X(XtX)^{-1}Xt = P = projeção
> P2 <- X%*%solve(Xt%*%X)%*%C1t%*%solve(C1t%*%solve(Xt%*%X)%*%C1t)%*%C1%*%solve(Xt%*%X)%*%Xt
> Yp <- Y - X%*%B0 # Y_{+}
> Ypt <- t(Yp)
>
> lambda_obs <- det(Yt%*%P%*%Y)/det(Yt%*%P%*%Y+Ypt%*%P2%*%Yp) # Estatística lambda^{2/n} do TRV
> lambda_obs
```

[1] 0.6715128

Observa-se também que poderia ser considerado $B_0 = \begin{pmatrix} 0 & 0 \\ 32 & 55 \end{pmatrix}$,

e chegaria-se no mesmo resultado da estatística do teste observada $\lambda^{2/n}$, ou seja, não importa qual solução para B_0 tal que $C_1 B_0 = D$ escolha, pois a estatística do teste será a mesma:

```
> # alterando apenas as partes que dependem de B_0 e chega-se no mesmo resultado que anteriormente
> B0 <- matrix(c(0,0,32,55), byrow = T, ncol=2, nrow=2)
> Yp <- Y - X%*%B0 # Y_{+}
> Ypt <- t(Yp)
> lambda_obs <- det(Yt%*%P%*%Y)/det(Yt%*%P%*%Y+Ypt%*%P2%*%Yp) # Estatística lambda^{2/n} do TRV
> lambda_obs
```

```
[1] 0.6715128
```

Tem-se então que $\lambda^{2/n} \stackrel{H_0}{\sim} \Lambda(p, n-1, g)$, ou seja, com $p = 2, n = 50, g = 1 \Rightarrow \lambda^{2/n} \stackrel{H_0}{\sim} \Lambda(2, 49, 1)$. Pode-se usar a relação com a distribuição F, em que:

$$\frac{1 - \Lambda(p, m, 1)}{\Lambda(p, m, 1)} \sim \frac{p}{m - p + 1} F_{p, m-p+1}$$

Portanto,

$$\begin{aligned} \frac{1 - \Lambda(2, 49, 1)}{\Lambda(2, 49, 1)} &\sim \frac{2}{49 - 2 + 1} F_{2, 49-2+1} = \frac{2}{48} F_{2, 48} \\ \Rightarrow \frac{48}{2} \frac{1 - \lambda^{2/n}}{\lambda^{2/n}} &\stackrel{H_0}{\sim} F_{2, 48} \end{aligned}$$

Usando a estatística do teste observada, tem-se $\lambda_{obs}^{2/n} = 0.6715128$, então:

```
> transf_lambda_obs <- 24*(1-lambda_obs)/lambda_obs
> pvalor <- 1-pf(transf_lambda_obs, df1=2, df2=48) # quantil da estatística transformada observada
> pvalor
```

```
[1] 7.068114e-05
```

Portanto, encontrou-se um p-valor $< 0,05$ então rejeita-se hipótese nula dos coeficientes serem iguais a zero. Ou seja, rejeita-se $\{H_0 : \beta_{11} = \beta_{12} = 0$ a nível de 5% de significância.

Código

```

library(tidyverse)
library(dplyr)
library(readxl)
vendedores <- read_excel("vendedores.xlsx")

# Obtenção através do método multivariado
Y = as.matrix(vendedores[c("X1", "X2")])
X = as.matrix(vendedores[c("X4", "X7")])

B_hat = solve(t(X)%*%X)%*%t(X)%*%Y
colnames(B_hat) <- NULL; rownames(B_hat) <- NULL
print(B_hat)

# Obtenção através do método univariado
y = c(Y)
x = kronecker(diag(1,nrow=2), X)

b_hat = solve(t(x)%*%x)%*%t(x)%*%y
print(b_hat)

e <- Y - X%*%B_hat
mu_e <- t(c(mean(e[1]), mean(e[2]))); mu_e
S <- cov(e); S

D_M <- apply(e, FUN=function(x) sqrt((x-mu_e)%*%solve(S)%*%t(x-mu_e)), MARGIN=1)
# ou equivalentemente: > sqrt(mahalanobis(e,center = mu_e, cov = S))
D_M

# Teste de Henze-Zirklers para normalidade multivariada
par(cex=0.95)
test_MN <- MVN::mvn(e,mvnTest = "hz",desc = F, multivariatePlot = "qq")

# p-valor do teste
test_MN$multivariateNormality

n <- nrow(Y) # n = número de unidades amostrais
Yt <- t(Y) # Y transposto
Xt <- t(X) # X transposto
C1 <- matrix(c(1,0),ncol=2, nrow=1) # C_1
C1t <- t(C1)
B0 <- matrix(c(0,0,4,3), byrow = T, ncol=2, nrow=2)

P <- diag(1,nrow = n) - X%*%solve(Xt%*%X)%*%Xt # I - X(XtX)^{-1}Xt = P = projeção
P2 <- X%*%solve(Xt%*%X)%*%C1t%*%solve(C1%*%solve(Xt%*%X)%*%C1t)%*%C1%*%solve(Xt%*%X)%*%Xt
Yp <- Y - X%*%B0 # Y_{+}
Ypt <- t(Yp)

lambda_obs <- det(Yt%*%P%*%Y)/det(Yt%*%P%*%Y+Ypt%*%P2%*%Yp)# Estatística lambda^{2/n} do TRV
lambda_obs

# alterando apenas as partes que dependem de B_0 e chega-se no mesmo resultado que anteriormente
B0 <- matrix(c(0,0,32,55), byrow = T, ncol=2, nrow=2)
Yp <- Y - X%*%B0 # Y_{+}
Ypt <- t(Yp)
lambda_obs <- det(Yt%*%P%*%Y)/det(Yt%*%P%*%Y+Ypt%*%P2%*%Yp)# Estatística lambda^{2/n} do TRV
lambda_obs

transf_lambda_obs <- 24*(1-lambda_obs)/lambda_obs
pvalor <- 1-pf(transf_lambda_obs, df1=2, df2=48) # quantil da estatística transformada observada
pvalor

```


MAE330 - Análise Multivariada de Dados

Lista 8

1.) $Y = XB + E$, com $Y = \begin{pmatrix} y_{11} & y_{12} \\ y_{21} & y_{22} \\ y_{31} & y_{32} \end{pmatrix}$, $X = \begin{pmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ x_{31} & x_{32} \end{pmatrix}$, $B = \begin{pmatrix} \beta_{11} & \beta_{12} \\ \beta_{21} & \beta_{22} \end{pmatrix}$

e $\Sigma = \begin{pmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{pmatrix}$, onde $\sigma_{11} \equiv$ variabilidade na coluna 1 de Y
 $\sigma_{21} \equiv$ covariância entre colunas 1 e 2 de Y

a) $\text{vec}(Y) = y = \begin{pmatrix} y_{11} \\ y_{21} \\ y_{31} \\ y_{12} \\ y_{22} \\ y_{32} \end{pmatrix}$, $\text{vec}(B) = \beta = \begin{pmatrix} \beta_{11} \\ \beta_{21} \\ \beta_{12} \\ \beta_{22} \end{pmatrix}$

$\text{vec}(E) = \varepsilon$ e $X^* = I_2 \otimes X = \begin{bmatrix} X_{3 \times 2} & 0_{3 \times 2} \\ 0_{3 \times 2} & X_{3 \times 2} \end{bmatrix} = \begin{bmatrix} x_{11} & x_{12} & 0 & 0 \\ x_{21} & x_{22} & 0 & 0 \\ x_{31} & x_{32} & 0 & 0 \\ 0 & 0 & x_{11} & x_{12} \\ 0 & 0 & x_{21} & x_{22} \\ 0 & 0 & x_{31} & x_{32} \end{bmatrix}$

$\Omega = \text{Var}(\varepsilon) = \Sigma \otimes I_3$, $\Omega = \begin{bmatrix} \sigma_{11} & 0 & 0 & \sigma_{12} & 0 & 0 \\ 0 & \sigma_{11} & 0 & 0 & \sigma_{12} & 0 \\ 0 & 0 & \sigma_{11} & 0 & 0 & \sigma_{12} \\ \sigma_{21} & 0 & 0 & \sigma_{22} & 0 & 0 \\ 0 & \sigma_{21} & 0 & 0 & \sigma_{22} & 0 \\ 0 & 0 & \sigma_{21} & 0 & 0 & \sigma_{22} \end{bmatrix}$, Ω é simétrica (linhas de Y diferentes são não-correlacionadas).

b) $E(\varepsilon) = E(\text{vec}(E)) = \text{vec}(E(E)) = \text{vec}(0) = 0$, pois $E(E) = 0$
 $\text{Var}(\varepsilon) = \text{Var}(\text{vec}(E)) = \Omega = \Sigma \otimes I_3$

Nota-se: $\begin{bmatrix} a & b \\ c & d \end{bmatrix} \otimes B = \begin{bmatrix} aB & bB \\ cB & dB \end{bmatrix}$

$\beta = (X^{*T} \Omega^{-1} X^*)^{-1} X^{*T} \Omega^{-1} y$ (I)

Usa-se então a propriedade do produto de Kronecker em que $(A \otimes B)(C \otimes D) = AC \otimes BD$ e além disso $(A \otimes B)^T = A^T \otimes B^T$ bem como $(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$

\therefore de (I):

$\beta = \left[(I_2 \otimes X)^T (\Sigma \otimes I_3)^{-1} (I_2 \otimes X) \right]^{-1} (I_2 \otimes X)^T (\Sigma \otimes I_3)^{-1} \text{vec}(Y)$
 $\beta = \left[(I_2 \otimes X^T) (\Sigma^{-1} \otimes I_3) (I_2 \otimes X) \right]^{-1} (I_2 \otimes X^T) (\Sigma^{-1} \otimes I_3) \text{vec}(Y)$
 $\left\{ \begin{array}{l} I^{-1} = I \\ \text{e } I^{-1} = I \end{array} \right.$

Usando (II):
$$= (\Sigma^{-1} \otimes X^T)$$

$$\begin{aligned} \Rightarrow \beta &= \left[(I_2 \Sigma^{-1} \otimes X^T I_2) (I_2 \otimes X) \right]^{-1} (I_2 \Sigma^{-1} \otimes X^T I_2) \text{vec}(Y) \\ &= (\Sigma^{-1} I_2 \otimes X^T X)^{-1} (\Sigma^{-1} \otimes X^T) \text{vec}(Y) \\ &= (\Sigma \otimes (X^T X)^{-1}) (\Sigma^{-1} \otimes X^T) \text{vec}(Y) \\ &= (\Sigma \cdot \Sigma^{-1} \otimes (X^T X)^{-1} \cdot X^T) \text{vec}(Y) = (I_2 \otimes (X^T X)^{-1} X^T) \text{vec}(Y) \end{aligned}$$

Logo, $\beta = [I_2 \otimes ((X^T X)^{-1} X^T)] \text{vec}(Y)$ ~~(III)~~, ou seja, não depende de Ω e Σ .

c) Primeiramente prova-se o seguinte Teorema: $\text{vec}(A \times B) = (B^T \otimes A) \text{vec}(X)$

Prova: Toma-se $B = \begin{bmatrix} b_{11} & b_{12} & \dots & b_{1m} \\ \vdots & \vdots & & \vdots \\ b_{m1} & b_{m2} & \dots & b_{mm} \end{bmatrix}_{(m \times m)}$, $X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1m} \\ \vdots & \vdots & & \vdots \\ x_{p1} & x_{p2} & \dots & x_{pm} \end{bmatrix}_{(p \times m)}$, $A = \begin{bmatrix} a_{11} & \dots & a_{1p} \\ \vdots & & \vdots \\ a_{m1} & \dots & a_{mp} \end{bmatrix}_{(m \times p)}$

Então a k -ésima coluna de $A \times B$ é:

$$\begin{aligned} (A \times B)_{:,k} &= A \times b_{:,k} = A \sum_{i=1}^m x_i \cdot b_{i,k} = [b_{1,k} A \quad b_{2,k} A \quad \dots \quad b_{m,k} A] \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} \\ &= [(b_{1,k} \quad b_{2,k} \quad \dots \quad b_{m,k}) \otimes A] \text{vec}(X) \end{aligned}$$

$$\text{vec}(A \times B) = \begin{bmatrix} (A \times B)_{:,1} \\ (A \times B)_{:,2} \\ \vdots \\ (A \times B)_{:,m} \end{bmatrix} = \begin{bmatrix} b_{1,1}^T \otimes A \\ b_{1,2}^T \otimes A \\ \vdots \\ b_{1,m}^T \otimes A \end{bmatrix} \cdot \text{vec}(X) = (B^T \otimes A) \cdot \text{vec}(X) \quad \blacksquare$$

Usando tal teorema em (III):

$$\beta = \text{vec}(B) = [I_2 \otimes ((X^T X)^{-1} X^T)] \cdot \text{vec}(Y) \stackrel{I_2^T = I_2}{=} \text{vec} \left(\underbrace{[(X^T X)^{-1} X^T]}_{\equiv A \text{ do Teorema}} \cdot \underbrace{Y \cdot I_2}_{\equiv B \text{ do Teorema}} \right)$$

$\therefore \text{vec}(B) = \text{vec}((X^T X)^{-1} X^T Y)$, pois $Y \cdot I_2 = Y$
 $(3 \times 2)(2 \times 2) \quad 3 \times 2$

e então:

$$B = \underbrace{(X^T X)^{-1}}_{2 \times 2} \underbrace{X^T}_{2 \times 3} \underbrace{Y}_{3 \times 2}$$